

引言

在数理统计学中，总体的分布是未知的。它包括两种情形：

- 1) 总体分布的类型是已知的，但其中包含未知参数。我们的任务就是通过样本来估计这些未知参数。这就是参数估计问题。
- 2) 总体分布的类型是未知的。我们的任务就是通过样本来估计总体的分布。这就是非参数估计问题。我们这里只讨论参数估计问题。

例：

设总体 X 是服从参数为 λ 的指数分布，其中参数 λ 未知， $\lambda > 0$. X_1, \dots, X_n 是总体 X 的一个样本，我们的任务是根据样本 来估计 λ 的取值，从而估计总体的分布 .

这是一个参数估计问题

第七章 参数估计

§ 1 点估计

§ 2 估计量的评选标准

第七章 参数估计

§ 1 点估计

- 点估计问题
- 矩法
- 极大似然法

一、点估计问题

设总体 X 的分布函数 $F(x; \theta)$ 的形式为已知, θ 是待估参数。 X_1, \dots, X_n 是 X 的一个样本, x_1, \dots, x_n 是相应的样本值。

构造一个适当的统计量 $\hat{\theta}(X_1, \dots, X_n)$, 用它的观察值 $\hat{\theta}(x_1, \dots, x_n)$ 来估计未知参数 θ 。

我们称 $\hat{\theta}(X_1, \dots, X_n)$ 为 θ 的估计量;

称 $\hat{\theta}(x_1, \dots, x_n)$ 为 θ 的估计值。

这种对未知参数进行定值估计的问题就是点估计问题。

注意：

(1) 估计量与估计值有着本质的不同：

估计量是统计量，因而它是随机变量（一维或多维）；而估计值则是一维或多维数组。

(2) 在不引起混淆的情况下，我们统称估计量与估计值为未知参数 θ 的估计。

二、矩估计法

设 X 为连续型随机变量, 其概率密度为

$$f(x; \theta_1, \cdots, \theta_k),$$

X 为离散型随机变量, 其分布列为

$$P\{X = x\} = P(x; \theta_1, \cdots, \theta_k),$$

其中 $\theta_1, \cdots, \theta_k$ 是待估参数, X_1, \cdots, X_n 为来自 X 的样本.

设 $EX^l = \mu_l$ 存在, $l = 1, 2, \cdots, k$

则 $\mu_l = \mu_l(\theta_1, \cdots, \theta_k), l = 1, 2, \cdots, k.$

令 $A_l = \mu_l, l = 1, \cdots, k$, 其中 $A_l = \frac{1}{n} \sum_{i=1}^n X_i^l$

这是包含 k 个未知参数 $\theta_1, \dots, \theta_k$ 的联立方程组,

$$\begin{cases} A_1 = \mu_1(\theta_1, \theta_2, \dots, \theta_k) \\ A_2 = \mu_2(\theta_1, \theta_2, \dots, \theta_k) \\ \dots \dots \dots \dots \\ A_k = \mu_k(\theta_1, \theta_2, \dots, \theta_k) \end{cases}$$

从中解出方程组的解记为 $\hat{\theta}_1, \dots, \hat{\theta}_k$, 即

$$\begin{cases} \hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n) \\ \hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n) \\ \dots \dots \dots \dots \\ \hat{\theta}_k = \hat{\theta}_k(X_1, X_2, \dots, X_n) \end{cases}$$

用 $\hat{\theta}_1, \dots, \hat{\theta}_k$ 分别作为 $\theta_1, \dots, \theta_k$ 的估计量,
这种求估计量的方法称为矩估计法

这种估计量称为矩估计量; 矩估计量的观察值称为矩估计值。

矩法原理: 由辛钦大数定律知

$$A_l = \frac{1}{n} \sum_{i=1}^n X_i^l \xrightarrow{P} \mu_l, \quad l = 1, 2, \dots, k.$$

所以我们令 $A_l = \mu_l, \quad l = 1, \dots, k$, 用 A_l 估计 μ_l .

矩法求估计量的步骤：

1) 求 $\mu_1 = EX, \mu_2 = EX^2 \dots$;

2) 令 $A_1 = \mu_1, A_2 = \mu_2 \dots$;

3) 解上面方程（组），得

$$\hat{\theta}_1 = \hat{\theta}_1(X_1, \dots, X_n)$$

$$\hat{\theta}_2 = \hat{\theta}_2(X_1, \dots, X_n)$$

...

例 1 设某炸药厂一天中发生着火现象的次数 X 服从参数为 λ 的泊松分布, λ 未知, 有以下样本值: 试估计参数 λ (用矩法)。

着火的次数 k	0	1	2	3	4	5	6	
发生 k 次着火天数 n_k	75	90	54	22	6	2	1	$\sum = 250$

解: $\mu_1 = EX = \lambda, \quad A_1 = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$

令 $\bar{X} = \lambda,$

则 $\hat{\lambda} = \bar{x} = \frac{1}{250} (0 \times 75 + 1 \times 90 + \cdots + 6 \times 1) = 1.22$

所以估计值 $\hat{\lambda} = 1.22$ 。

例2

设总体 $X \sim U[a, b]$, a, b 未知, X_1, \dots, X_n 是一个样本,
求: a, b 的矩估计量。

解: $\mu_1 = EX = \frac{a+b}{2},$

$$\mu_2 = EX^2 = DX + (EX)^2 = \frac{(b-a)^2}{12} + \frac{(a+b)^2}{4}$$

令 $\frac{a+b}{2} = A_1$

即 $a+b = 2A_1,$

$$\frac{(b-a)^2}{12} + \frac{(a+b)^2}{4} = A_2 \quad b-a = \sqrt{12(A_2 - A_1^2)}$$

例2 (续)

$$\text{即 } a + b = 2A_1, \quad b - a = \sqrt{12(A_2 - A_1^2)}$$

解得:

$$\hat{a} = A_1 - \sqrt{3(A_2 - A_1^2)} = \bar{X} - \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$$

$$\hat{b} = A_1 + \sqrt{3(A_2 - A_1^2)} = \bar{X} + \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$$

$$A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

例3 设总体 X 的均值 μ , 方差 σ^2 都存在, 且 $\sigma^2 > 0$, 但 μ, σ^2 未知, 又设 X_1, \dots, X_n 是一个样本; 求: μ, σ^2 的矩估计量。

解: $\mu_1 = EX = \mu,$

$$\mu_2 = EX^2 = DX + (EX)^2 = \sigma^2 + \mu^2$$

令 $\mu_1 = A_1, \mu_2 = A_2,$

即 $\mu = A_1, \sigma^2 + \mu^2 = A_2,$

所以 $\hat{\mu} = A_1 = \bar{X},$

$$\hat{\sigma}^2 = A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

特别, 若 $X \sim N(\mu, \sigma^2)$, μ, σ^2 未知;

$$\text{则 } \hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

例4 设总体 X 服从参数为 λ 的指数分布, 其中 $\lambda > 0$ 未知, X_1, X_2, \dots, X_n 是从该总体中抽取的一个样本, 试求参数 λ 的矩估计.

解: 总体 X 的密度函数为

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

所以, $EX = \int_{-\infty}^{+\infty} xf(x)dx = \int_0^{+\infty} x \cdot \lambda e^{-\lambda x} dx = \frac{1}{\lambda}$

令

$$\bar{X} = \frac{1}{\lambda},$$

得参数 λ 的矩估计量为

$$\hat{\lambda} = \frac{1}{\bar{X}}.$$

例5 设总体 X 的密度函数为

$$f(x) = \begin{cases} (\alpha + 1)x^\alpha, & 0 < x < 1, \\ 0, & \text{其它.} \end{cases}$$

其中 $\alpha > 0$ 为未知参数, 试求参数 α 的矩估计.

解:

$$EX = \int_{-\infty}^{+\infty} xf(x)dx = \int_0^1 x \cdot (\alpha + 1)x^\alpha dx = \frac{\alpha + 1}{\alpha + 2}$$

$$\text{令} \quad \bar{X} = \frac{\hat{\alpha} + 1}{\hat{\alpha} + 2}$$

$$\text{由此得 } \alpha \text{ 的矩估计量为 } \hat{\alpha} = \frac{2\bar{X} - 1}{1 - \bar{X}}.$$

例6 设总体 X 服从 Γ -分布, 其密度函数为

$$f(x) = \begin{cases} \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

其中 $\alpha > 0$, $\beta > 0$ 为未知参数, 试求参数 α 与 β 的矩估计.

解: $EX = \int_{-\infty}^{+\infty} xf(x)dx = \int_0^{+\infty} x \cdot \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} dx$

$$= \frac{\Gamma(\alpha+1)}{\beta \Gamma(\alpha)} \int_0^{+\infty} \frac{\beta^{\alpha+1}}{\Gamma(\alpha+1)} x^{(\alpha+1)-1} e^{-\beta x} dx$$
$$= \frac{\Gamma(\alpha+1)}{\beta \Gamma(\alpha)} = \frac{\alpha \Gamma(\alpha)}{\beta \Gamma(\alpha)} = \frac{\alpha}{\beta}$$

例6(续)

$$EX^2 = \int_{-\infty}^{+\infty} x^2 f(x) dx = \int_0^{+\infty} x^2 \cdot \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} dx$$

$$= \frac{\Gamma(\alpha+2)}{\beta^2 \Gamma(\alpha)} \int_0^{+\infty} \frac{\beta^{\alpha+2}}{\Gamma(\alpha+2)} x^{(\alpha+2)-1} e^{-\beta x} dx$$

$$= \frac{\Gamma(\alpha+2)}{\beta^2 \Gamma(\alpha)} = \frac{\alpha(\alpha+1)\Gamma(\alpha)}{\beta^2 \Gamma(\alpha)} = \frac{\alpha(\alpha+1)}{\beta^2}$$

因此有

$$\begin{cases} EX = \frac{\alpha}{\beta}, \\ EX^2 = \frac{\alpha(\alpha+1)}{\beta^2}. \end{cases} \quad \text{令} \quad \begin{cases} A_1 = \frac{\alpha}{\beta}, \\ A_2 = \frac{\alpha(\alpha+1)}{\beta^2}. \end{cases}$$

例6(续)

解此方程组，得

$$\left\{ \begin{array}{l} \hat{\alpha} = \frac{A_1^2}{A_2 - A_1^2}, \\ \hat{\beta} = \frac{A_1}{A_2 - A_1^2}. \end{array} \right. \quad \text{即} \quad \left\{ \begin{array}{l} \hat{\alpha} = \frac{\bar{X}^2}{B_2}, \\ \hat{\beta} = \frac{\bar{X}}{B_2}. \end{array} \right.$$

其中 $B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 为样本的二阶中心矩.

三、极大似然法

例1 如果一个射手击中目标的概率可能是

$$p = \frac{1}{5}, \frac{8}{15}, \frac{4}{5}.$$

现在让他打三发子弹，在不同的命中目标的次数下，我们应该如何取 p 的估计值 \hat{p} ？

解：用 X 表示命中目标的次数，则 $X \sim B(3, p)$, 即

$$P\{X = x\} = C_3^x p^x (1-p)^{3-x} = P(x; p).$$

计算结果列表如下：

例1 (续)

命中次数 x	0	1	2	3
$P(x; \frac{1}{5})$	$\frac{1728}{3375}$	$\frac{1296}{3375}$	$\frac{324}{3375}$	$\frac{27}{3375}$
$P(x; \frac{8}{15})$	$\frac{343}{3375}$	$\frac{1176}{3375}$	$\frac{1344}{3375}$	$\frac{512}{3375}$
$P(x; \frac{4}{5})$	$\frac{27}{3375}$	$\frac{324}{3375}$	$\frac{1296}{3375}$	$\frac{1728}{3375}$

因为 $P(0; \frac{1}{5}) > P(0; \frac{8}{15}) > P(0; \frac{4}{5})$,

这表明, $p = \frac{1}{5}$ 使得打三发子弹命中次数为0的概率最大

由实际推断原理知, 此时应取 $\hat{p} = \frac{1}{5}$.

例1 (续) 命中次数 x	0	1	2	3
$P(x; \frac{1}{5})$	$\frac{1728}{3375}$	$\frac{1296}{3375}$	$\frac{324}{3375}$	$\frac{27}{3375}$
$P(x; \frac{8}{15})$	$\frac{343}{3375}$	$\frac{1176}{3375}$	$\frac{1344}{3375}$	$\frac{512}{3375}$
$P(x; \frac{4}{5})$	$\frac{27}{3375}$	$\frac{324}{3375}$	$\frac{1296}{3375}$	$\frac{1728}{3375}$

因此，由上表可得下面的结论：

打三发命中次数 $x=1$ 时，命中率 p 的合理估计 $\hat{p} = \frac{1}{5}$ ；

打三发命中次数 $x=2$ 时，命中率 p 的合理估计 $\hat{p} = \frac{8}{15}$ ；

打三发命中次数 $x=3$ 时，命中率 p 的合理估计 $\hat{p} = \frac{4}{5}$ 。

1) 若总体 X 属离散型, 其分布律

$$P\{X = x\} = p(x; \theta), \theta \in \Theta$$

的形式为已知, θ 为待估参数, Θ 是 θ 可能取值的范围。
设 X_1, \dots, X_n 是来自 X 的样本, 则 X_1, \dots, X_n 的联合分布律:

$$\prod_{i=1}^n p(x_i; \theta)$$

又设 x_1, \dots, x_n 是 X_1, \dots, X_n 的一个样本值,

易知样本 X_1, \dots, X_n 取 x_1, \dots, x_n 的概率, 亦即

事件 $\{X_1 = x_1, \cdots, X_n = x_n\}$ 发生的概率为:

$$L(\theta) = L(x_1, \cdots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta), \theta \in \Theta.$$

它是 θ 的函数. $L(\theta)$ 称为样本的似然函数

极大似然法原理:

固定 x_1, \cdots, x_n , 挑选使概率 $L(x_1, \cdots, x_n; \theta)$ 达到最大的参数 $\hat{\theta}$, 作为 θ 的估计值, 即取 $\hat{\theta}$ 使得:

$$L(x_1, \cdots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, \cdots, x_n; \theta)$$

$\hat{\theta}$ 与 x_1, \cdots, x_n 有关, 记为 $\hat{\theta}(x_1, \cdots, x_n)$;

称其为参数 θ 的极大似然估计值

$\hat{\theta}(X_1, \dots, X_n)$ 称为参数 θ 的极大似然估计量


这种求未知参数 θ 的方法称为极大似然法

2) 若总体 X 属连续型, 其概率密度 $(x; \theta), \theta \in \Theta$ 的形式已知, θ 为待估参数. 则 X_1, \dots, X_n 的联合密度:

$$\prod_{i=1}^n f(x_i; \theta)$$

设 x_1, \dots, x_n 是相应 X_1, \dots, X_n 的一个样本值, 则随机点 (X_1, \dots, X_n) 落在 (x_1, \dots, x_n) 的邻域 (边长分别为 dx_1, \dots, dx_n 的 n 维立方体) 内的概率近以为:

$$\prod_{i=1}^n f(x_i; \theta) dx_i$$



在得到观测值 (x_1, x_2, \dots, x_n) 的前提下, 自然应当选取使得

$$\prod_{i=1}^n f(x_i; \theta) dx_i$$

达到最大的 θ 值作为未知参数 θ 的估计值.
因为当未知参数 θ 等于这个值时, 出现给定的那个样本观测值的可能性最大.

但 $\prod_i dx_i$ 不随 θ 而变, 故只需考虑:

$$L(\theta) = L(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta),$$

的最大值, 这里 $L(\theta)$ 称为样本的似然函数.

若 $L(x_1, \cdots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, \cdots, x_n; \theta)$

则称 $\hat{\theta}(x_1, \cdots, x_n)$ 为 θ 的极大似然估计值

称 $\hat{\theta}(X_1, \cdots, X_n)$ 为 θ 的极大似然估计量

一般, $p(x; \theta), f(x; \theta)$ 关于 θ 可微, 故 θ 可由下式求得:

$$\frac{dL(\theta)}{d\theta} = 0 \text{ ----- 似然方程}$$

又因 $L(\theta)$ 与 $\ln L(\theta)$ 在同一 θ 处取到极值, 因此 θ 的极大似然估计 θ 也可从下述方程解得:

$$\frac{d}{d\theta} \ln L(\theta) = 0 \text{ ----- 对数似然方程}$$

若总体的分布中包含多个参数,

即可令 $\frac{\partial L}{\partial \theta_i} = 0, i = 1, \dots, k$ -----似然方程组

或 $\frac{\partial \ln L}{\partial \theta_i} = 0, i = 1, \dots, k$ -----对数似然方程组

解 k 个方程组求得 $\theta_1, \dots, \theta_k$ 的极大似然估计值。

即可得 $\theta_1, \dots, \theta_k$ 的极大似然估计量。

一般来讲, 极大似然估计优于矩估计, 因而在应用中, 我们应当尽可能地使用极大似然估计

极大似然法求估计量的步骤：（一般情况下）

1) 构造似然函数 $L(\theta)$:

$$L(\theta) = \prod_{i=1}^n P(x_i) \text{ (离散型)}, \quad L(\theta) = \prod_{i=1}^n f(x_i) \text{ (连续型)};$$

2) 取对数: $\ln L(\theta)$;

3) 令 $\frac{d \ln L}{d \theta} = 0$;

4) 解似然方程得 θ 的极大似然估计量 $\hat{\theta}$.

说明：若似然方程（组）无解，或似然函数不可导，此法失效，改用其它方法。

例2 设 $X \sim B(1, p)$; X_1, \dots, X_n 是来自 X 的一个样本, 试求参数 p 的极大似然估计量。

解: 设 x_1, \dots, x_n 是一个样本值。 X 的分布律为:

$$P\{X = x\} = p^x (1-p)^{1-x}, \quad x = 0, 1;$$

故似然函数为

$$L(p) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i},$$

$$\text{而 } \ln L(p) = \left(\sum_{i=1}^n x_i\right) \ln p + \left(n - \sum_{i=1}^n x_i\right) \ln(1-p).$$

例2 (续)

$$\ln L(p) = \left(\sum_{i=1}^n x_i \right) \ln p + \left(n - \sum_{i=1}^n x_i \right) \ln(1-p)$$

令 $\frac{d}{dp} \ln L(p) = 0$, 即
$$\frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} = 0.$$

解得 p 的极大似然估计值
$$\hat{p} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

p 的极大似然估计量为

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

-----它与矩估计量是相同的。

例3 设 $X \sim N(\mu, \sigma^2)$; μ 已知, σ^2 为未知参数, x_1, \dots, x_n 是来自 X 的一个样本值求 σ^2 的极大似然估计量

解: X 的概率密度为:

$$f(x; \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\}$$

似然函数为:

$$\begin{aligned} L(\mu, \sigma^2) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2\sigma^2}(x_i - \mu)^2\right\} \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} \end{aligned}$$

$$\ln L = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

例3 (续)

$$\ln L = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

$$\frac{d \ln L}{d \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2$$

$$\text{令: } \frac{d \ln L}{d \sigma^2} = 0,$$

$$\text{得似然方程 } -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0$$

$$\text{解此方程, 得 } \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2,$$

$$\text{因此 } \sigma^2 \text{ 的极大似然估计量为 } \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2.$$

例4 设 $X \sim N(\mu, \sigma^2)$; μ, σ^2 为未知参数, x_1, \dots, x_n 是来自 X 的一个样本值, 求 μ, σ^2 的极大似然估计量

解: X 的概率密度为:

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\}$$

似然函数为:

$$\begin{aligned} L(\mu, \sigma^2) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2\sigma^2}(x_i - \mu)^2\right\} \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}} \end{aligned}$$

$$\ln L = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

例4 (续)

$$\ln L = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

$$\text{令} \begin{cases} \frac{\partial \ln L}{\partial \mu} = 0 \\ \frac{\partial \ln L}{\partial \sigma^2} = 0 \end{cases} \quad \text{即:} \begin{cases} \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \\ -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0 \end{cases}$$

$$\text{解得: } \hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

故 μ, σ^2 的极大似然估计量为:

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X} \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

例5 设总体 X 的密度函数为

$$f(x) = \begin{cases} \theta x^{\theta-1}, & 0 < x < 1, \\ 0, & \text{其它.} \end{cases}$$

其中 θ 未知, $\theta > 1$, X_1, \dots, X_n 是从该总体抽取的一个样本. 试求 θ 的极大似然估计.

解: 似然函数为

$$L(\theta) = \theta^n \left(\prod_{i=1}^n x_i \right)^{\theta-1},$$

$$\ln L(\theta) = n \ln \theta + (\theta - 1) \sum_{i=1}^n \ln x_i$$

例5 (续)

$$\ln L = n \ln \theta + (\theta - 1) \sum_{i=1}^n \ln x_i$$

$$\frac{d \ln L}{d \theta} = \frac{n}{\theta} + \sum_{i=1}^n \ln x_i$$

$$\text{令: } \frac{d \ln L}{d \theta} = 0,$$

$$\text{得似然方程为 } \frac{n}{\theta} + \sum_{i=1}^n \ln x_i = 0,$$

$$\text{解得 } \hat{\theta} = -\frac{n}{\sum_{i=1}^n \ln x_i},$$

$$\text{因此 } \theta \text{ 的极大似然估计量为 } \hat{\theta} = -\frac{n}{\sum_{i=1}^n \ln X_i}.$$

例6 设 $X \sim U[a, b]$; a, b 未知, x_1, \dots, x_n 是一个样本值,
求: a, b 的极大似然估计量。

分析: X 的概率密度为: $f(x; a, b) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b; \\ 0 & , \text{其它} \end{cases}$

似然函数为

$$L(a, b) = \frac{1}{(b-a)^n} \quad (a < x_i < b, \quad i = 1, 2, \dots, n)$$

$$\ln L(a, b) = -n \ln(b-a),$$

$$\frac{\partial}{\partial a} \ln L(a, b) = \frac{n}{b-a} = 0; \quad \frac{\partial}{\partial b} \ln L(a, b) = -\frac{n}{b-a} = 0,$$

显然, 似然方程组无解, 但这不能说明不存在极大似然估计量, 只是不能由似然方程组求解。

例6 (续)

解: 将 x_1, \dots, x_n 按从小到大顺序排列成

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)},$$

$$\text{则 } L(a, b) = \begin{cases} \frac{1}{(b-a)^n}, & a \leq x_{(1)} \leq \dots \leq x_{(n)} \leq b; \\ 0, & \text{其它} \end{cases}$$

对于满足 $a \leq x_{(1)} \leq \dots \leq x_{(n)} \leq b$ 的任意 a, b 有

$$L(a, b) = \frac{1}{(b-a)^n} \leq \frac{1}{(x_{(n)} - x_{(1)})^n}$$

例6 (续)

即: $L(a,b)$ 在 $a = x_{(1)}, b = x_{(n)}$ 时,

取最大值 $(x_{(n)} - x_{(1)})^{-n}$

故 a, b 的极大似然估计值为:

$$\hat{a} = x_{(1)} = \min x_i, \quad \hat{b} = x_{(n)} = \max x_i,$$

故 a, b 的极大似然估计量为:

$$\hat{a} = \min X_i, \quad \hat{b} = \max X_i.$$

例7 一个罐子里装有黑球和白球，有放回地抽取 n 个球，发现有 k 个黑球。试求罐子里黑球数与白球数之比 R 的极大似然估计量。

解： 设罐中装有 a 只黑球 b 只白球，则 $R = \frac{a}{b}$ 。

设 $X_i = \begin{cases} 1, & \text{第} i \text{次摸到黑球;} \\ 0, & \text{第} i \text{次摸到白球.} \end{cases} \quad i = 1, \cdots, n.$

则 X_1, \cdots, X_n 是总体 $X \sim b(1, p)$ 的样本，

其中 $p = P\{X_i = 1\} = \frac{a}{a+b} = \frac{R}{1+R}$ 。

$$p = \frac{R}{1+R}$$

似然函数 $L(R) = \prod_{i=1}^n p(x_i) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i}$

$$= \prod_{i=1}^n \left(\frac{R}{1+R}\right)^{x_i} \left(1 - \frac{R}{1+R}\right)^{1-x_i} = \left(\frac{R}{1+R}\right)^{\sum_{i=1}^n x_i} \left(1 - \frac{R}{1+R}\right)^{n - \sum_{i=1}^n x_i},$$

则 $\ln L = \sum_{i=1}^n x_i \ln\left(\frac{R}{1+R}\right) + \left(n - \sum_{i=1}^n x_i\right) \ln\left(\frac{1}{1+R}\right)$

$$= \sum_{i=1}^n x_i [\ln R - \ln(1+R)] - \left(n - \sum_{i=1}^n x_i\right) \ln(1+R)$$

令 $\frac{d \ln L}{dR} = 0$, 则 $\sum_{i=1}^n x_i \left(\frac{1}{R} - \frac{1}{1+R}\right) - \left(n - \sum_{i=1}^n x_i\right) \frac{1}{1+R} = 0$

解出 $\hat{R} = \frac{\sum_{i=1}^n x_i}{n - \sum_{i=1}^n x_i} = \frac{k}{n - k}.$

极大似然估计性质:

设 θ 的函数 $u = u(\theta)$, $\theta \in \Theta$ 具有单值反函数, $\hat{\theta}$ 是 θ 的极大似然估计; 则 $\hat{u} = u(\hat{\theta})$ 是 $u(\theta)$ 的极大似然估计。

例: $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 是 σ^2 的极大似然估计,

$u = u(\sigma^2) = \sqrt{\sigma^2}$ 有单值反函数 $\sigma^2 = u^2, (u \geq 0)$

故 $\hat{\sigma} = \sqrt{\hat{\sigma}^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$ 是 σ 的极大似然估计.

例8 设 $X \sim N(\mu, \sigma^2)$, μ, σ^2 未知, 求使 $P\{X > A\} = 0.05$ 的点 A 的极大似然估计量

解: $P\{X > A\} = 1 - \Phi\left(\frac{A - \mu}{\sigma}\right) = 0.05$

查表有 $\frac{A - \mu}{\sigma} = 1.645$, 所以 $A = \mu + 1.645\sigma$.

由前面知 μ 和 σ^2 的极大似然估计量分别为

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

所以 A 的极大似然估计量为

$$\hat{A} = \hat{\mu} + 1.645\hat{\sigma} = \bar{X} + 1.645\sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}.$$

第七章 参数估计

§ 2 估计量的评选标准

- 无偏性
- 有效性
- 一致性

我们注意到，在上一节中对于同一个未知参数，用不同方法可以得到不同的估计量。究竟采用哪个为好呢？这就涉及到用什么标准来评价估计量的问题。我们介绍三个常用的标准：

- 1) 无偏性；
- 2) 有效性；
- 3) 一致性。

一、无偏性

若 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ 的数学期望存在, 且 $E\hat{\theta} = \theta$, 则称 $\hat{\theta}$ 是 θ 的无偏估计量。

例1 X_1, \dots, X_n 是总体 $X \sim N(\mu, \sigma^2)$ 的样本,
 μ, σ^2 均未知.

因为 $E\bar{X} = \mu$, 所以 $\hat{\mu} = \bar{X}$ 是 μ 的无偏估计量

而 $ES^2 = \sigma^2$,

所以 $\hat{\sigma}^2 = S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 是 σ^2 的无偏估计量.

考察 $B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$

由于
$$\begin{aligned} E(B_2) &= E\left\{ \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \right\} \\ &= E\left\{ \frac{n-1}{n} \cdot \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \right\} \\ &= \frac{n-1}{n} E(S^2) = \frac{n-1}{n} \sigma^2 \end{aligned}$$

因此, $B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 是总体方差 σ^2 的有偏估计.

例2 设总体 X 存在 m 阶矩, 并设

$$EX^k = \mu_k, \quad (k = 1, 2, \dots, m)$$

X_1, \dots, X_n 是总体 X 的样本, 又设 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$

是样本的 k 阶原点矩, $(k = 1, 2, \dots, m)$

$$\text{由于 } E(A_k) = E\left(\frac{1}{n} \sum_{i=1}^n X_i^k\right) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = \frac{1}{n} \sum_{i=1}^n \mu_k = \mu_k$$

因此 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 是总体的 k 阶原点矩 μ_k 的无偏估计.
 $(k = 1, 2, \dots, m)$

例3 设总体 X 服从区间 $[0, \theta]$ 上的均匀分布, 其中 $\theta > 0$ 为未知参数, X_1, \dots, X_n 是从该总体中抽取的一个样本. 求 θ 的矩估计, 并验证是否是无偏估计.

解: $EX = \frac{\theta}{2},$

令 $\bar{X} = \frac{\theta}{2}$, 得 θ 的矩估计量为 $\hat{\theta} = 2\bar{X}.$

由于

$$E(\hat{\theta}) = E(2\bar{X}) = 2E(\bar{X}) = 2E(X) = 2 \cdot \frac{\theta}{2} = \theta,$$

因此 $\hat{\theta} = 2\bar{X}$ 是未知参数 θ 的无偏估计.

例4 设总体 $X \sim N(\mu, \sigma^2)$, 其中 μ 已知, 而 $\sigma^2 > 0$ 为未知参数, X_1, \dots, X_n 是从该总体中抽取的一个样本. 则由 § 7.1 例3知, 未知参数 σ^2 的极大似然估计为

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$$

由于 $\frac{X_i - \mu}{\sigma} \sim N(0, 1), i = 1, \dots, n$, 且它们独立,

$$\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 \sim \chi^2(n)$$

例4 (续)

因此,

$$\begin{aligned} E(\hat{\sigma}^2) &= E\left(\frac{\sigma^2}{n} \sum_{i=1}^n \frac{(X_i - \mu)^2}{\sigma^2}\right) \\ &= \frac{\sigma^2}{n} E\left(\sum_{i=1}^n \frac{(X_i - \mu)^2}{\sigma^2}\right) = \frac{\sigma^2}{n} \times n = \sigma^2 \end{aligned}$$

这表明, $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$ 是总体方差 σ^2 的无偏估计.

说明:

如果未知参数 θ 有两个不同的无偏估计 $\hat{\theta}_1$ 与 $\hat{\theta}_2$,
则 θ 一定有无穷多个无偏估计.

这是因为, 对任意的实数 α ,

$$\alpha\hat{\theta}_1 + (1-\alpha)\hat{\theta}_2$$

一定是未知参数 θ 的无偏估计.

二、有效性

若 $\hat{\theta}_1 = \hat{\theta}_1(X_1, \dots, X_n)$, $\hat{\theta}_2 = \hat{\theta}_2(X_1, \dots, X_n)$ 都是 θ 的无偏估计量, 且 $D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$, 则称 $\hat{\theta}_1$ 较 $\hat{\theta}_2$ 有效.
 $D(\hat{\theta}_1) = E(\hat{\theta}_1 - E\hat{\theta}_1)^2 = E(\hat{\theta}_1 - \theta)^2$ 表示 $\hat{\theta}_1$ 与 θ 的偏离程度.

例5 设总体 $X \sim N(\mu, \sigma^2)$, 其中 μ 未知,

X_1, X_2, X_3 是从该总体中抽取的一个样本.

试验证: $\hat{\mu}_1 = \frac{1}{5}X_1 + \frac{3}{10}X_2 + \frac{1}{2}X_3$;

$\hat{\mu}_2 = \frac{1}{3}X_1 + \frac{1}{4}X_2 + \frac{5}{12}X_3$; $\hat{\mu}_3 = \frac{1}{3}X_1 + \frac{1}{6}X_2 + \frac{1}{2}X_3$

都是未知参数 μ 的无偏估计, 并指出在这三个 μ 的估计中, 哪一个最有效?

例5 (续) **解:** 由于

$$\begin{aligned} E(\hat{\mu}_1) &= E\left(\frac{1}{5}X_1 + \frac{3}{10}X_2 + \frac{1}{2}X_3\right) \\ &= \frac{1}{5}E(X_1) + \frac{3}{10}E(X_2) + \frac{1}{2}E(X_3) = \frac{1}{5}\mu + \frac{3}{10}\mu + \frac{1}{2}\mu = \mu \end{aligned}$$

$$\begin{aligned} E(\hat{\mu}_2) &= E\left(\frac{1}{3}X_1 + \frac{1}{4}X_2 + \frac{5}{12}X_3\right) \\ &= \frac{1}{3}E(X_1) + \frac{1}{4}E(X_2) + \frac{5}{12}E(X_3) = \frac{1}{3}\mu + \frac{1}{4}\mu + \frac{5}{12}\mu = \mu \end{aligned}$$

$$\begin{aligned} E(\hat{\mu}_3) &= E\left(\frac{1}{3}X_1 + \frac{1}{6}X_2 + \frac{1}{2}X_3\right) \\ &= \frac{1}{3}E(X_1) + \frac{1}{6}E(X_2) + \frac{1}{2}E(X_3) = \frac{1}{3}\mu + \frac{1}{6}\mu + \frac{1}{2}\mu = \mu \end{aligned}$$

例5 (续)

这表明, $\hat{\mu}_1$, $\hat{\mu}_2$, $\hat{\mu}_3$ 都是未知参数 μ 的无偏估计.

$$\begin{aligned} D(\hat{\mu}_1) &= D\left(\frac{1}{5}X_1 + \frac{3}{10}X_2 + \frac{1}{2}X_3\right) \\ &= \frac{1}{25}D(X_1) + \frac{9}{100}D(X_2) + \frac{1}{4}D(X_3) \\ &= \frac{1}{25}\sigma^2 + \frac{9}{100}\sigma^2 + \frac{1}{4}\sigma^2 = \frac{684}{1800}\sigma^2 \end{aligned}$$

$$\begin{aligned} D(\hat{\mu}_2) &= D\left(\frac{1}{3}X_1 + \frac{1}{4}X_2 + \frac{5}{12}X_3\right) \\ &= \frac{1}{9}D(X_1) + \frac{1}{16}D(X_2) + \frac{25}{144}D(X_3) \\ &= \frac{1}{9}\sigma^2 + \frac{1}{16}\sigma^2 + \frac{25}{144}\sigma^2 = \frac{625}{1800}\sigma^2 \end{aligned}$$

例5 (续)

$$\begin{aligned} D(\hat{\mu}_3) &= D\left(\frac{1}{3}X_1 + \frac{1}{6}X_2 + \frac{1}{2}X_3\right) \\ &= \frac{1}{9}D(X_1) + \frac{1}{36}D(X_2) + \frac{1}{4}D(X_3) \\ &= \frac{1}{9}\sigma^2 + \frac{1}{36}\sigma^2 + \frac{1}{4}\sigma^2 = \frac{700}{1800}\sigma^2 \end{aligned}$$

由于 $D(\hat{\mu}_2) < D(\hat{\mu}_1) < D(\hat{\mu}_3)$,

所以在 $\hat{\mu}_1$ 、 $\hat{\mu}_2$ 、 $\hat{\mu}_3$ 这三个估计量中,
 $\hat{\mu}_2$ 最有效.

例6 设总体 X 存在二阶矩，并设

$$EX = \mu, \quad DX = \sigma^2,$$

X_1, \dots, X_n 是总体 X 的一个样本，又设

$$a_i \geq 0, \quad i = 1, 2, \dots, n, \quad \text{且} \quad \sum_{i=1}^n a_i = 1.$$

试证：

(1) $\sum_{i=1}^n a_i X_i$ 是 μ 的无偏估计；

(2) 在 μ 的所有形如上述的 $\sum_{i=1}^n a_i X_i$ 估计中， \bar{X} 的方差最小。

例6 (续)

证明:

(1) 由于

$$E\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i E(X_i) = \sum_{i=1}^n a_i \mu = \mu$$

所以, $\sum_{i=1}^n a_i X_i$ 是 μ 的无偏估计.

(2) 由 *Schwarz* 不等式,

$$\left(\sum_{i=1}^n u_i v_i\right)^2 \leq \left(\sum_{i=1}^n u_i^2\right) \cdot \left(\sum_{i=1}^n v_i^2\right)$$

在上面的不等式中, 令

例6 (续)

$$u_i = 1, i = 1, 2, \dots, n;$$

$$v_i = a_i, i = 1, 2, \dots, n.$$

则有

$$\left(\sum_{i=1}^n a_i \right)^2 \leq n \cdot \left(\sum_{i=1}^n a_i^2 \right)$$

$$\text{所以, } D\bar{X} = \frac{DX}{n} = \frac{DX}{n} \cdot \left(\sum_{i=1}^n a_i \right)^2 \quad \left(\text{因为 } \sum_{i=1}^n a_i = 1 \right)$$

$$\leq \frac{DX}{n} \cdot n \left(\sum_{i=1}^n a_i^2 \right) = DX \cdot \left(\sum_{i=1}^n a_i^2 \right)$$

例6 (续)

$$D\bar{X} \leq DX \cdot \left(\sum_{i=1}^n a_i^2 \right) = \sum_{i=1}^n a_i^2 DX$$

$$= \sum_{i=1}^n a_i^2 DX_i = \sum_{i=1}^n D(a_i X_i) = D\left(\sum_{i=1}^n a_i X_i \right)$$

这表明，在 μ 的所有形如 $\sum_{i=1}^n a_i X_i$ 的无偏估计中， \bar{X} 的方差为最小，即 \bar{X} 为最有效。

三、一致性

若 $\hat{\theta} = \hat{\theta}_n(X_1, \dots, X_n)$ 为参数 θ 的估计量, 如果对于任意 $\theta \in \Theta$, 当 $n \longrightarrow \infty$ 时 $\hat{\theta}_n \xrightarrow{P} \theta$. 则称 $\hat{\theta}$ 是 θ 的一致估计。

例7 若 X_1, \dots, X_n 是总体 X 的样本, $EX = \mu$, $EX^k = \mu_k$. 由辛钦大数定律, 知对于任意给定的 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| \geq \varepsilon \right\} = 0$$

因此, 样本均值 \bar{X} 是总体期望 μ 的一致估计量.

例7 (续)

还有
$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i^k - \mu_k \right| \geq \varepsilon \right\} = 0$$

因此，样本的 k 阶原点矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 是总

体 k 阶原点矩 $\mu_k = EX^k$ 的一致估计量.